

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
22.	Fundamentos y Aplicación de la Lógica Difusiva	3
22.1.	Introducción	3
22.2.	Fundamentos Teóricos	4
22.2.1.	Conjuntos difusos y grados de pertenencia	4
22.2.2.	Funciones de membresía	4
22.2.3.	Arquitectura de un sistema de inferencia difusa	5
22.2.4.	Modelos de inferencia: Mamdani y Takagi-Sugeno-Kang	5
22.2.5.	Lógica difusa de tipo 2	6
22.2.6.	Sistemas jerárquicos de lógica difusa	6
22.3.	Metodología y Análisis de la Literatura	7
22.3.1.	Control de robots móviles y colaborativos	7
22.3.2.	Control de vehículos aéreos no tripulados	8
22.3.3.	Vehículos autónomos terrestres y sistemas ADAS	8
22.3.4.	Gestión de energía: microrredes, vehículos eléctricos y fotovoltaica	9
22.3.5.	Control de tráfico y ciudades inteligentes	10
22.3.6.	Procesos industriales	10
22.3.7.	Sistemas híbridos: neuro-difusos y genético-difusos	11
22.3.8.	Aplicaciones no convencionales	11
22.3.9.	Desafíos y limitaciones identificadas en la literatura	12
22.4.	Conclusiones	13

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 22

Fundamentos y Aplicación de la Lógica Difusiva

Autor: Steven Alexander Jumbo Jaramillo (steven.a.jumbo@unl.edu.ec)
Técnica asignada: Lógica Difusiva

22.1. Introducción

Hay un problema que los ingenieros de control han enfrentado durante décadas: el mundo real no es binario. La temperatura de un horno industrial no pasa de “fría” a “caliente” en un instante preciso, un vehículo autónomo no enfrenta situaciones perfectamente definidas, y un dron que vuela en exteriores no opera bajo condiciones constantes ni predecibles. Sin embargo, durante gran parte del siglo XX, los sistemas de control se diseñaron exactamente bajo esa premisa: que todo puede reducirse a valores exactos, modelos matemáticos precisos y umbrales rígidos. La lógica difusa surgió precisamente para cuestionar esa premisa [2].

El Dr. Lotfi Zadeh introdujo los conjuntos difusos en 1965, y con ello abrió la puerta a una forma distinta de representar el conocimiento en sistemas automáticos [4]. La idea central era sencilla pero poderosa: en lugar de obligar a que un valor pertenezca o no pertenezca a una categoría, permitir grados de pertenencia. Así, algo puede ser “parcialmente rápido” o “bastante cercano”, de la misma manera en que un humano razona de forma natural. Esta capacidad de trabajar con imprecisión sin perder coherencia lógica es lo que hace a la lógica difusa especialmente útil para el diseño de sistemas de control inteligente [22].

En los años que siguieron a la publicación de Zadeh, el campo creció de forma sostenida. Hoy, la lógica difusa no es una curiosidad teórica: es una herramienta concreta que aparece en controladores industriales, vehículos autónomos, drones, sistemas de gestión de energía, semáforos inteligentes e incluso en la optimización del entrenamiento deportivo [23]. Su versatilidad proviene de que no requiere un modelo matemático exacto del sistema que se desea controlar, lo que la convierte en una opción especialmente valiosa cuando la dinámica del sistema es compleja, no lineal, o simplemente difícil de caracterizar con ecuaciones [19].

El presente capítulo tiene como propósito guiar al lector a través de los fundamentos de esta técnica y mostrar, con base en evidencia reciente de la literatura científica, cómo se aplica concretamente en el desarrollo de sistemas de control inteligente. Para ello, el capítulo se organiza de la siguiente manera: primero se establecen los fundamentos teóricos de la lógica difusa, explicando sus componentes esenciales, los modelos de inferencia más utilizados y las extensiones más relevantes como los sistemas de tipo 2 y los sistemas jerárquicos. Posteriormente, en la sección de metodología y análisis de la literatura, se presentan y discuten las aplicaciones más significativas documentadas en artículos científicos recientes, organizadas por dominio: robótica, vehículos aéreos no tripulados, transporte autónomo, gestión de energía, control de tráfico, pro-

cesos industriales, sistemas híbridos, y aplicaciones no convencionales. Finalmente, se presentan las conclusiones del capítulo, donde se reflexiona sobre el estado actual de la técnica y hacia dónde apunta su evolución.

Al terminar de leer este capítulo, el lector comprenderá no solo cómo funciona la lógica difusa internamente, sino también por qué sigue siendo relevante en un panorama tecnológico cada vez más dominado por el aprendizaje profundo y los modelos estadísticos complejos. Entenderá sus ventajas, sus limitaciones reales, y el tipo de problemas donde su aplicación produce resultados que otros enfoques difícilmente pueden igualar con la misma sencillez y transparencia.

22.2. Fundamentos Teóricos

22.2.1. Conjuntos difusos y grados de pertenencia

La lógica clásica opera sobre conjuntos nítidos: un elemento pertenece o no pertenece a un conjunto, sin posibilidad intermedia. La lógica difusa rechaza esa dicotomía y permite que un elemento pertenezca parcialmente a un conjunto, con un grado de membresía que varía en el intervalo continuo $[0, 1]$ [4]. Esta distinción, aparentemente simple, tiene consecuencias profundas para el diseño de sistemas que deben operar con datos reales, que casi siempre son ruidosos, incompletos o ambiguos [2].

Formalmente, dado un universo de discurso X , un conjunto difuso A se define mediante una función de membresía $\mu_A : X \rightarrow [0, 1]$, donde $\mu_A(x)$ indica el grado en que el elemento x pertenece al conjunto A . Cuando $\mu_A(x) = 1$, la pertenencia es total; cuando $\mu_A(x) = 0$, el elemento no pertenece en absoluto; y cualquier valor intermedio representa una pertenencia parcial [4].

Por ejemplo, si se define el conjunto difuso “alta temperatura” para un horno industrial, un valor de 85 °C podría tener un grado de pertenencia de 0.7 a ese conjunto, mientras que simultáneamente tendría un grado de 0.3 al conjunto “temperatura media”. Esta superposición es precisamente lo que permite modelar transiciones graduales, y es la base sobre la cual se construyen los controladores difusos [2].

22.2.2. Funciones de membresía

Las funciones de membresía son el componente concreto que da forma a los conjuntos difusos. Su elección influye directamente en la sensibilidad del sistema ante cambios en las variables de entrada y, por tanto, en la suavidad y precisión de la respuesta de control [11].

Los tipos más utilizados en la literatura son:

Triangulares (trimf): Se definen por tres parámetros: un límite inferior a , un vértice central b donde la membresía es total, y un límite superior c . Son las más comunes en aplicaciones de control por su simplicidad computacional y facilidad de ajuste manual. Se emplean frecuentemente en control de motores, gestión de tráfico y sistemas de entrenamiento deportivo [31].

Trapezoidales (trapmf): Extienden la forma triangular añadiendo una meseta de membresía total entre cuatro parámetros a, b, c, d . Son útiles para representar variables que mantienen un estado estable durante un intervalo, como la detección de distancias en robots móviles o el control de errores de rumbo en vehículos autónomos [8].

Gaussianas: Definidas por su centro c y su desviación estándar σ , producen curvas suaves y continuas. Son preferidas en control aeroespacial, navegación de drones y modelos neuro-difusos donde se requiere diferenciabilidad para procesos de optimización [10].

Singletons y funciones de campana: Los singletons asignan membresía total a un único punto y se usan habitualmente en los consecuentes del modelo Sugeno. Las funciones de campana ofrecen mayor flexibilidad en la curvatura y se aplican en sistemas con mayor variabilidad de los datos de entrada [12].

En sistemas avanzados como los de tipo 2 o los neuro-difusos adaptativos, los parámetros de estas funciones pueden ajustarse automáticamente durante la operación, lo que permite que el controlador se adapte a cambios en el entorno sin intervención manual [23].

22.2.3. Arquitectura de un sistema de inferencia difusa

Un Sistema de Inferencia Difusa (FIS, por sus siglas en inglés) transforma valores numéricos de entrada en una salida igualmente numérica, pasando a través de tres etapas bien diferenciadas [2]:

Fuzzificación: Es el paso inicial donde los valores de las variables de entrada, obtenidos de sensores u otras fuentes, se convierten en grados de membresía dentro de los conjuntos difusos definidos. Por ejemplo, una velocidad de 45 km/h podría clasificarse simultáneamente como “media” con grado 0.8 y “alta” con grado 0.2 [30]. Esta transformación es la que permite al sistema operar con conceptos lingüísticos en lugar de valores numéricos exactos.

Motor de inferencia: Es el núcleo del sistema. Aquí se evalúa la base de reglas, compuesta por sentencias condicionales de la forma “*SI (condición) ENTONCES (consecuencia)*”. El motor determina qué reglas se activan según los grados de membresía obtenidos en la fuzzificación, y combina los resultados usando operadores lógicos como el mínimo (para la intersección, operador AND) y el máximo (para la unión de reglas activas) [16]. El resultado de esta etapa es, a su vez, un conjunto difuso que representa la respuesta del sistema ante la situación analizada.

Defuzzificación: Como los actuadores físicos no pueden procesar directamente conjuntos difusos, esta etapa convierte la salida del motor de inferencia en un valor numérico concreto. El método más utilizado es el centroide o centro de gravedad, que calcula el centro geométrico del área formada por todos los conjuntos difusos de salida activos [19]. Otra alternativa común es el promedio ponderado, computacionalmente más liviano, que calcula la salida en función de la fuerza de activación de cada regla y sus valores representativos.

La ecuación general de un controlador difuso con n reglas activas mediante el método de promedio ponderado se expresa como:

$$u = \frac{\sum_{i=1}^n w_i \cdot z_i}{\sum_{i=1}^n w_i} \quad (22.1)$$

donde u es la salida de control, w_i es la fuerza de disparo (firing strength) de la regla i , y z_i es el valor representativo del consecuente de esa regla [10].

22.2.4. Modelos de inferencia: Mamdani y Takagi-Sugeno-Kang

En la práctica, los dos modelos de inferencia difusa más utilizados en el diseño de controladores son el de Mamdani y el de Takagi-Sugeno-Kang (TSK). Sus diferencias son fundamentales para elegir cuál aplicar en un contexto determinado [19].

Modelo de Mamdani: El consecuente de cada regla es un conjunto difuso definido mediante etiquetas lingüísticas como “Bajo”, “Medio” o “Alto”. Esto lo hace muy intuitivo y fácil de interpretar por un operador humano, ya que tanto las entradas como las salidas se expresan en términos naturales. Es la elección preferida para sistemas de control de procesos, robótica y aplicaciones donde se busca replicar el razonamiento de un experto humano [30]. Su desventaja principal es que la defuzzificación por centroide es computacionalmente intensiva, lo que puede ser limitante en aplicaciones de tiempo real estricto.

Modelo Takagi-Sugeno-Kang (TSK): En este modelo, el consecuente de cada regla no es un conjunto difuso sino una función matemática de las variables de entrada, generalmente una constante (modelo de orden cero) o una función lineal (modelo de orden uno). Esto hace que la defuzzificación se reduzca a un promedio ponderado de valores numéricos, con un costo computacional significativamente menor. Su compatibilidad con algoritmos de optimización como el descenso de gradiente lo convierte en la base natural de los sistemas neuro-difusos ANFIS [5].

Además, facilita el análisis formal de estabilidad mediante criterios como el de Lyapunov, lo cual es crítico en aplicaciones de seguridad. La tabla 22.1 resume las diferencias más relevantes.

Tabla 22.1: Comparación entre los modelos de inferencia Mamdani y Takagi-Sugeno-Kang.

Característica	Mamdani	Takagi-Sugeno-Kang
Tipo de consecuente	Conjunto difuso lingüístico	Función matemática (constante o lineal)
Defuzzificación	Centroide (costosa)	Promedio ponderado (eficiente)
Interpretabilidad	Alta	Moderada
Análisis de estabilidad	Difícil	Factible (Lyapunov)
Compatibilidad con aprendizaje	Limitada	Alta (ANFIS, GA)
Aplicaciones típicas	Procesos, robótica, expertos	Tiempo real, modelado, predicción

22.2.5. Lógica difusa de tipo 2

La lógica difusa convencional, ahora llamada de tipo 1, asume que los grados de membresía de los conjuntos difusos son valores exactos. Sin embargo, en entornos reales donde los sensores son ruidosos, los expertos tienen opiniones divergentes o las condiciones del sistema varían ampliamente, incluso esa suposición puede resultar demasiado optimista [11].

La lógica difusa de tipo 2 extiende el modelo permitiendo que el propio grado de membresía sea a su vez un conjunto difuso. Esto introduce la denominada *Footprint of Uncertainty* (FOU), que es la región delimitada por una función de membresía superior (UMF) y una función de membresía inferior (LMF), y que representa la incertidumbre sobre cómo definir un concepto lingüístico [12]. Para producir una salida numérica, los sistemas de tipo 2 requieren un paso adicional: el *reductor de tipo*, que transforma el conjunto de tipo 2 en un conjunto de tipo 1 antes de la defuzzificación. Los algoritmos de Karnik-Mendel y su versión mejorada (EKM) son los métodos estándar para esta tarea [11].

En la práctica, los controladores de tipo 2 han demostrado ser más robustos ante el ruido de los sensores y ante cambios imprevistos en el sistema, aunque su diseño y ajuste son más complejos que los de tipo 1 [8].

22.2.6. Sistemas jerárquicos de lógica difusa

Uno de los problemas más serios que enfrenta un diseñador de controladores difusos es la explosión combinatoria de la base de reglas. En un sistema con n variables de entrada y m funciones de membresía por variable, el número de reglas crece como m^n . Para sistemas de múltiples entradas y múltiples salidas (MIMO) esto se vuelve rápidamente inmanejable [4].

Los sistemas jerárquicos de lógica difusa (HFS) resuelven este problema descomponiendo el sistema en varios subsistemas de menor dimensión, organizados en capas. Cada capa procesa un subconjunto de las variables de entrada, y sus salidas alimentan a los niveles superiores de la jerarquía. El crecimiento de reglas pasa de m^n a una escala aproximadamente lineal de $(n-1) \cdot m^2$, lo que representa una reducción drástica [4]. En sistemas MIMO, esta arquitectura permite identificar variables comunes a múltiples salidas y diseñar una unidad compartida para su procesamiento, evitando la duplicación y reduciendo la complejidad computacional global.

22.3. Metodología y Análisis de la Literatura

El análisis que se presenta en esta sección se basa en la revisión de 35 artículos científicos publicados en revistas y conferencias indexadas, con un rango temporal que abarca desde 2019 hasta 2026. Los artículos fueron seleccionados con criterio de representatividad temática, cubriendo los dominios de aplicación más activos de la lógica difusa en sistemas de control inteligente. A continuación se presentan los hallazgos organizados por área de aplicación.

22.3.1. Control de robots móviles y colaborativos

La robótica es uno de los campos donde la lógica difusa ha encontrado mayor y más sostenida aplicación. El desafío central en este dominio es que los robots deben tomar decisiones en tiempo real con base en datos de sensores que frecuentemente son imprecisos, incompletos o ruidosos, exactamente las condiciones para las que la lógica difusa fue concebida [1].

En el ámbito de los robots móviles autónomos, los controladores Fuzzy-PID han demostrado ser una alternativa sólida a los controladores clásicos para tareas de seguimiento de trayectoria y evitación de obstáculos. Yousfi Allagui et al. [6] propusieron un algoritmo de programación de ganancias difusas para un robot diferencial no holonómico, donde el sistema difuso ajusta dinámicamente los parámetros K_p , K_i y K_d del controlador PID en función del error de posición y su derivada. Esta sintonización adaptativa elimina el principal problema de los PID clásicos: que son estáticos y solo son óptimos para un punto de operación específico. Los resultados mostraron una reducción significativa del sobreimpulso y de los errores cuadráticos respecto al controlador fijo.

Para tareas de navegación multi-objetivo en entornos con obstáculos dinámicos, Stavrinidis et al. [16] propusieron una arquitectura con dos controladores difusos paralelos: uno dedicado al seguimiento del camino óptimo calculado mediante un algoritmo de tipo viajante (TSP), y otro con prioridad absoluta para la evitación de colisiones en tiempo real. Las simulaciones en CoppeliaSim reportaron una tasa de éxito del 100 % en alcanzar todos los puntos de inspección sin colisiones en entornos con humanos moviéndose de forma impredecible.

Un enfoque distinto fue planteado por Mújica-Vargas et al. [8], quienes emplearon un árbol de inferencia difusa de tipo 2 para la navegación de un robot diferencial en interiores. La arquitectura distribuyó las tareas de evitación, recuperación de ruta y llegada a meta en diferentes niveles del árbol lógico. La métrica de suavidad de trayectoria obtenida fue de 0.236 rad, superior a la de algoritmos clásicos como RRT y PRM, lo que se traduce en menor consumo energético y transiciones más fluidas.

En los robots colaborativos (cobots), el enfoque cambia: la prioridad es garantizar la seguridad de los operadores humanos en espacios compartidos. Sousa et al. [7] integraron reglas difusas con una red neuronal convolucional (YOLOv3) para que un cobot en un almacén ajustara su velocidad y rumbo en tiempo real según la clase y distancia del objeto detectado (humano, herramienta u obstáculo inerte). Las pruebas en el simulador ROS-Gazebo mostraron tiempos de ciclo más rápidos que el sistema de navegación estándar de ROS, manteniendo distancias de seguridad superiores respecto a los obstáculos. Por su parte, Autso et al. [1] revisaron el estado del arte en control difuso para cobots, identificando que los métodos híbridos que combinan lógica difusa con aprendizaje profundo logran reducciones de errores de seguimiento superiores al 40 % respecto a controladores de modo deslizante convencionales, con la ventaja adicional de eliminar el fenómeno de *chattering* que degrada la vida útil de los componentes mecánicos.

Un sistema evolutivo de tipo 2 (T2-EFCS), propuesto por Al-Mahturi et al. [12], demostró que es posible construir controladores que aprenden sus propias reglas desde cero, partiendo de una única regla inicial y actualizándolas de forma continua mediante un método de superficie deslizante basado en descenso de gradiente. Los valores de RMSE reportados fueron significativamente menores que los de controladores de tipo 1 y de referencia bajo perturbaciones

externas, con la particularidad de que la estabilidad se verificó formalmente mediante la teoría de Lyapunov.

22.3.2. Control de vehículos aéreos no tripulados

Los vehículos aéreos no tripulados (UAVs) son quizás el dominio más exigente para cualquier controlador: sus dinámicas son altamente no lineales, están fuertemente acopladas entre ejes, y deben operar bajo perturbaciones externas impredecibles como ráfagas de viento. La lógica difusa se ha aplicado en este campo principalmente a través de dos estrategias: la sintonización en línea de los parámetros PID y la programación adaptativa de ganancias [9].

Andrade et al. [9] desarrollaron un esquema de PID en cascada donde un sistema de inferencia difusa ajusta las ganancias del lazo externo de posición en tiempo real, sin necesidad del modelo matemático formal del dron. La solución fue evaluada mediante simulaciones en Unreal Engine 4 con el plugin AirSim, y comparada con el método de Ziegler-Nichols, otro enfoque difuso y el controlador integrado de ArduPilot. El método difuso propuesto alcanzó el punto de destino 1.5 segundos más rápido que el controlador de ArduPilot, con un error acumulado notablemente menor.

Melo et al. [10] extendieron esta idea con una estrategia de programación de ganancias difusas que diferencia entre el control de posición y el de altitud, priorizando el control de altura en condiciones críticas. Los resultados mostraron un error de posición inferior al 2 % respecto al controlador PID convencional en presencia de ruido, con una mayor suavidad en las trayectorias seguidas.

Para cuadricópteros sometidos a condiciones más severas, Madebo [3] realizó una comparación entre tres estrategias: un controlador difuso puro (Fuzzy), un Fuzzy-PID (FPID) y un Fuzzy-PID optimizado por algoritmos genéticos (GAFPID). Las simulaciones incluyeron perturbaciones externas y variaciones de parámetros, evaluadas mediante el índice ITAE. El GAFPID resultó superior en precisión, adaptabilidad y rechazo a perturbaciones de hasta 15 m/s, con reducciones de error del 87 % en posición y del 70 % en actitud respecto al PID tradicional. El uso de controladores de tipo 2 fue explorado por Chu et al. [11], quienes diseñaron un controlador IT2F-PID mediante un método de optimización gradual desacoplada (D-GO), reportando una reducción del sobreimpulso del 80 % y una disminución del índice ITAE del 95 % respecto a un controlador difuso de tipo 2 construido con el método general.

Yang et al. [18] abordaron el problema del control bajo fallos de actuadores combinando un modo deslizante integral con lógica difusa y un observador neuronal. El sistema resultante demostró estabilidad en tiempo finito incluso bajo restricciones físicas severas en los actuadores, eliminando el *chattering* y manteniendo la convergencia ante perturbaciones simultáneas.

22.3.3. Vehículos autónomos terrestres y sistemas ADAS

En el transporte terrestre autónomo, la lógica difusa aparece principalmente en tres funciones: navegación, evitación de colisiones y frenado adaptativo. Lo que hace interesante su aplicación aquí es que el sistema debe operar con datos de múltiples sensores que a menudo son contradictorios, en entornos que cambian de forma continua [13].

Jitender et al. [14] implementaron un controlador difuso para la gestión de colisiones en vehículos autónomos circulando en carriles de tráfico, evaluando escenarios con diferentes densidades vehiculares. Los resultados confirmaron que el controlador difuso produce perfiles de aceleración más suaves y decisiones más anticipadas que los sistemas de reglas fijas, reduciendo la probabilidad de colisión en hasta un 32 %. Ahmad et al. [13] abordaron el mismo problema desde una perspectiva de optimización convexa en redes vehiculares (VANETs), y al comparar su método con un sistema de evasión difusa clásico (FLCA), encontraron que la integración de ambas técnicas logra una reducción adicional del 19 % en el consumo de combustible.

Para el frenado adaptativo, Shaout y Castaneda-Trejo [17] desarrollaron un controlador difuso implementado en un microcontrolador STM32, que procesa tres entradas simultáneas: distancia al obstáculo, velocidad del vehículo y un índice de condición de la carretera (RCI). Este índice permite al sistema distinguir si el pavimento está seco, mojado o congelado, y ajustar la fuerza de frenado de forma proporcional a la peligrosidad real de la situación. Las pruebas mostraron que el sistema produce respuestas suaves y calibradas, en contraste con los sistemas binarios que frenan de forma abrupta e igualmente intensa independientemente de las condiciones del suelo.

El control de cruce adaptativo en carreteras con pendientes, que constituye uno de los escenarios más complicados para los PID clásicos, fue abordado por Choi y Chang [5] mediante un ANFIS entrenado con datos de escenarios donde el ángulo de la pendiente variaba. El sistema aprendió a compensar la aceleración gravitacional sin necesidad de un modelo explícito de la inclinación, mostrando un rendimiento estable en condiciones de carretera desconocidas para las que no había sido entrenado directamente.

Para la evasión de obstáculos en alta velocidad y con diferentes condiciones de adherencia, Dong et al. [15] propusieron un marco de control predictivo difuso de dos etapas (Fuzzy-MPC), donde un sistema de inferencia difusa optimizado offline mediante Particle Swarm Optimization (PSO) y optimización bayesiana ajusta en tiempo real los pesos del costo del MPC. Comparado con un MPC de referencia, el método redujo el error lateral de seguimiento entre un 6 % y un 38 % dependiendo del escenario, con mejoras de hasta el 49 % en la precisión de rumbo.

22.3.4. Gestión de energía: microrredes, vehículos eléctricos y fotovoltaica

La gestión energética es un dominio donde la lógica difusa tiene una ventaja clara: los sistemas de energía modernos integran fuentes renovables intermitentes, almacenamiento no lineal y cargas variables, todo lo cual produce dinámicas difíciles de modelar con precisión. Los controladores difusos no necesitan ese modelo; solo necesitan reglas razonables y funciones de membresía bien ajustadas [27].

Al Sumarmad et al. [27] desarrollaron un sistema de gestión de energía para microrred basado en lógica difusa, con monitoreo en tiempo real mediante la plataforma ThingSpeak. El controlador difuso regula el flujo de potencia entre los generadores distribuidos y las cargas, y decide dinámicamente cuándo cargar o descargar la batería según el estado del bus DC. Los resultados de simulación en MATLAB confirmaron la factibilidad del enfoque para regular frecuencia y voltaje bajo diferentes condiciones de operación.

En el sector de vehículos eléctricos, Shenbagalakshmi et al. [31] implementaron un controlador difuso para el control de velocidad de motores BLDC en aplicaciones de propulsión eléctrica. Comparado con el PID clásico, el controlador difuso produjo transiciones de velocidad sin sobreimpulso y con error en estado estacionario nulo, alcanzando un tiempo de asentamiento de apenas 0.05 s frente a los 0.1 s del PID. Bajo variaciones de carga, la respuesta de par del FLC se mantuvo constante alrededor de 1.05 Nm, mientras que el PID mostró oscilaciones y rizado de par considerables. Por su parte, Divya y Kumar [25] aplicaron lógica difusa a la gestión de energía en vehículos eléctricos de celda de combustible (FCHEV), donde el controlador difuso coordina la potencia entre la celda y la batería durante los ciclos de conducción, manteniendo el estado de carga de la batería por encima del 99.9 % frente al 92 % obtenido con PID en pruebas simuladas.

En sistemas fotovoltaicos, Kaur et al. [29] emplearon un ANFIS optimizado mediante el método de Taguchi para el seguimiento del punto de máxima potencia (MPPT). El sistema toma como entradas la irradiancia y la temperatura de los paneles, y calcula directamente el voltaje óptimo para extraer la máxima potencia en tiempo real. Los resultados reportaron un valor de RMSE de 0.0054 y un coeficiente R^2 de 0.993, con una respuesta más rápida y menores oscilaciones que el método convencional de Perturbación y Observación (P&O).

22.3.5. Control de tráfico y ciudades inteligentes

El tráfico urbano es un sistema complejo caracterizado por incertidumbre alta, variabilidad temporal extrema y múltiples interacciones simultáneas entre agentes autónomos. Los semáforos de tiempo fijo, que fueron el estándar durante décadas, no pueden adaptarse a estas condiciones, lo que resulta en congestión innecesaria, emisiones elevadas y tiempos de viaje prolongados [30].

Juniana y Hakim [30] implementaron un prototipo de control de semáforos con lógica difusa Mamdani, utilizando sensores infrarrojos para medir la densidad vehicular en cada carril. El sistema difuso asigna tiempos de luz verde de 0, 5, 10 o 15 segundos adicionales según el nivel de congestión detectado, clasificado lingüísticamente como “estable”, “medio” o “congestionado”. La sencillez del sistema no impide que sea efectivo: el ajuste dinámico del tiempo verde redujo de forma medible los tiempos de espera en el prototipo evaluado.

A una escala de mayor complejidad, Wu et al. [32] propusieron el marco NeuroTraffic-Soft, que combina un mapa auto-organizado (SOM) para clasificar patrones de congestión espaciotemporal, una red neuronal recurrente (RNN) para predecir la evolución del flujo, y un controlador de lógica difusa de tipo 2 para la toma de decisiones bajo incertidumbre. Las simulaciones en un corredor urbano de 10 intersecciones interconectadas reportaron una reducción del 32.1 % en el tiempo de espera promedio, una disminución del 26.4 % en el número de paradas y un incremento del 17.9 % en la velocidad media de circulación, con robustez superior al 90 % ante datos ruidosos de sensores.

Las redes vehiculares ad hoc (VANETs) amplían este concepto al nivel de comunicación entre vehículos. Ahmad et al. [13] utilizaron un sistema de evasión de colisiones difuso (FLCA) como línea base de comparación en escenarios de tráfico denso con múltiples vehículos conectados, demostrando la utilidad de la lógica difusa como referente de rendimiento incluso frente a métodos de optimización más complejos.

22.3.6. Procesos industriales

En la industria, la lógica difusa se ha posicionado como una alternativa legítima a los controladores PID en procesos donde la dinámica es no lineal, los modelos matemáticos exactos son costosos de obtener o las condiciones de operación varían de forma continua [22].

En sistemas de climatización (HVAC), Chojecki et al. [28] compararon un controlador difuso con un PID estándar para una Unidad de Manejo de Aire (AHU) en un edificio comercial. El FLC logró mejoras de al menos el 27.4 % en todos los indicadores integrales de calidad de control (IAE, ISE, ITAE, ITSE), redujo el error cuadrático medio de temperatura en un 36 % y disminuyó el consumo energético en un 12.7 % respecto al PID no sintonizado. La implementación del FLC fue validada en hardware real mediante una tarjeta de control universal para AHU.

En la industria del gas natural, Martirosyan y Romashin [20] revisaron las estrategias de control para plantas de separación y purificación, concluyendo que los métodos inteligentes que combinan control adaptativo y lógica difusa superan consistentemente a los PID estáticos en términos de adaptabilidad ante fluctuaciones en la composición del gas crudo y en las condiciones de operación. La capacidad de ajuste dinámico de los controladores difusos resulta particularmente valiosa cuando la materia prima varía de un lote al siguiente, algo frecuente en la industria gasífera.

En el transporte de productos petrolíferos, Skripko y Skripko [21] presentaron métodos de control adaptativo para sistemas no estacionarios durante el bombeo de derivados del petróleo. Los algoritmos difusos analizan en tiempo real los cambios en viscosidad, presión y temperatura del fluido para ajustar los parámetros de bombeo, factores que varían drásticamente según las condiciones ambientales y la geografía del oleoducto.

Para el control de sistemas multivariable, Al-Hadithi y Gómez [19] integraron el modelo T-S difuso con el Análisis de Componentes Principales (PCA) para controlar un sistema de doble tanque. La reducción de dimensionalidad mediante PCA permitió disminuir el número de reglas

difusas necesarias, reduciendo la complejidad computacional sin comprometer la precisión del control, con error en estado estacionario nulo y respuestas transitorias suaves.

En el ámbito de la manufactura inteligente e Industria 4.0, Lee [22] revisó las aplicaciones de la lógica difusa junto con redes neuronales y algoritmos genéticos en la optimización de equipos, operaciones y controles de producción, señalando un crecimiento sostenido en publicaciones durante la última década y destacando el potencial de estas técnicas para la personalización de procesos en entornos de fabricación flexible.

22.3.7. Sistemas híbridos: neuro-difusos y genético-difusos

Uno de los desarrollos más significativos en el campo es la hibridación de la lógica difusa con otras técnicas de inteligencia artificial. Estas combinaciones buscan compensar las limitaciones individuales de cada enfoque: la lógica difusa aporta transparencia, interpretabilidad y manejo de la imprecisión; las redes neuronales aportan capacidad de aprendizaje automático; los algoritmos genéticos aportan optimización global sin necesidad de derivadas [23].

Los sistemas ANFIS (Adaptive Neuro-Fuzzy Inference System) son el ejemplo más consolidado de hibridación neuro-difusa. Como se mencionó, Kaur et al. [29] demostraron su eficacia en MPPT fotovoltaico, y Choi y Chang [5] los emplearon para generalizar el comportamiento del ACC a condiciones de carretera no vistas durante el entrenamiento. La clave del ANFIS es que aprende los parámetros de las funciones de membresía y las ganancias de las reglas a partir de datos, eliminando gran parte del proceso de ajuste manual.

Yang et al. [18] propusieron un controlador que combina modo deslizante integral con lógica difusa y un observador basado en redes neuronales. El observador neuronal estima los fallos del actuador en tiempo real, y el componente difuso ajusta la superficie de deslizamiento para mantener la estabilidad ante estos fallos. Este tipo de arquitectura es representativo de la tendencia actual: los componentes individuales son más simples y manejables cuando se integran adecuadamente [23].

La combinación con algoritmos genéticos ha demostrado ventajas especialmente claras en la optimización de controladores para UAVs. Madebo [3] mostró que el GAFPID supera tanto al FLC puro como al FPID estándar en precisión de seguimiento bajo perturbaciones severas, gracias a que el algoritmo genético encuentra combinaciones de parámetros que el diseño manual raramente alcanza. Un resultado similar fue reportado por Stavriniadis et al. [16] en navegación multi-objetivo de robots, donde la combinación de GA para la secuenciación de objetivos con controladores difusos para la evasión local produjo rutas más cortas y con mayor tasa de éxito.

En sistemas de control de inundaciones, Khanduri et al. [26] refinaron las reglas difusas mediante algoritmos genéticos, logrando una reducción del 25 % en los niveles de inundación y una precisión del 97.59 % en los sensores ultrasónicos validados por el sistema difuso. Wu et al. [32] demostraron que la integración de aprendizaje automático profundo con lógica difusa de tipo 2 mantiene niveles de robustez superiores al 90 % incluso cuando los sensores de tráfico presentan fallos o datos extremadamente ruidosos.

22.3.8. Aplicaciones no convencionales

Más allá de los dominios de aplicación tradicionales, la literatura reciente documenta usos de la lógica difusa en contextos que hasta hace poco eran difíciles de imaginar como receptores de esta técnica.

En el ámbito aeroespacial, Crespo et al. [33] diseñaron controladores difusos para la misión OPS-SAT-1 de la Agencia Espacial Europea, orientados al control de actitud del satélite en órbita. La metodología incluyó modelado del entorno espacial, análisis de factibilidad de actuadores, parametrización del controlador y sintonización mediante optimización genética multi-objetivo, con análisis de robustez mediante el método de Monte Carlo en 200 simulaciones. Los resultados indicaron que el controlador difuso puede superar al PID clásico en precisión de seguimiento,

tiempo de asentamiento y error en estado estacionario en escenarios nominales, aunque con un consumo energético menos eficiente bajo alta incertidumbre del modelo. Kamzan et al. [34] fueron aún más lejos, proponiendo un controlador híbrido que combina aprendizaje emocional basado en el cerebro (BELBIC), autoencoders profundos y lógica difusa para el control de actitud de un satélite orientado a la Tierra bajo dinámicas no lineales de alta fidelidad, incertidumbres paramétricas del $\pm 10\%$ y fallos parciales de actuadores. En el canal de cabeceo, el MSE se redujo de $1,01 \times 10^{-2}$ a $5,59 \times 10^{-3}$ respecto al BELBIC clásico, con mejoras similares en otros canales.

En el ámbito de la ciencia del deporte, Yan et al. [35] introdujeron el marco FC-TOF (Fuzzy Control-based Training Optimization Framework), que integra un FIS de tipo Sugeno con redes neuronales LSTM para ajustar la intensidad del entrenamiento en función de variables fisiológicas en tiempo real como la variabilidad de la frecuencia cardíaca, el esfuerzo percibido y el volumen de entrenamiento. En estudios con atletas de diversas disciplinas, el sistema reportó un incremento en la resistencia de aproximadamente el 95 % en etapas avanzadas de evaluación, una reducción del 60 % en las tasas de lesión y una mejora superior al 90 % en la eficiencia de la gestión de la recuperación, comparado con métodos tradicionales de planificación del entrenamiento.

En la gestión de desastres naturales, Khanduri et al. [26] implementaron un sistema de control de inundaciones basado en lógica difusa de tipo Sugeno, con sensores ultrasónicos y de caudal conectados a un NodeMCU ESP8266 con transmisión de datos en tiempo real a Telegram mediante Firebase. El sistema evalúa simultáneamente la eficiencia hidrológica, el estado tecnológico y las circunstancias funcionales de la infraestructura de drenaje mediante 125 criterios de inferencia, logrando una reducción del 25 % en los niveles de inundación.

En computación en la nube, Li [24] propuso un marco cognitivo de red-nube (CCNF) que integra predicción de carga mediante LSTM, orquestación mediante Proximal Policy Optimization (PPO) y control adaptativo difuso para la gestión de recursos en centros de datos distribuidos. Los experimentos con datos reales de Alibaba y Google reportaron una mejora del 23 % en la utilización de recursos, una reducción del 18 % en la latencia y una tasa de violación de SLA del 0.9 %.

22.3.9. Desafíos y limitaciones identificadas en la literatura

Una revisión honesta de la literatura no puede limitarse a los resultados positivos. Los artículos analizados también identifican limitaciones reales que es necesario reconocer para tener una perspectiva equilibrada del estado actual de la técnica.

El primero y más recurrente de estos problemas es la dependencia del diseño en el conocimiento experto. La selección de las funciones de membresía, la definición de los rangos de las variables y la formulación de la base de reglas siguen dependiendo en gran medida del criterio del diseñador, lo que introduce sesgos subjetivos y hace que el proceso sea costoso en tiempo cuando el sistema es complejo [3]. Este problema se atenúa con los sistemas adaptativos como el ANFIS, pero no desaparece por completo.

La explosión de la base de reglas en sistemas con muchas variables de entrada es otro obstáculo bien documentado. Para mitigarlo, los sistemas jerárquicos y los métodos de reducción dimensional como PCA ofrecen caminos viables, pero añaden complejidad al diseño [4].

En sistemas de tipo 2 y en arquitecturas híbridas, la mayor capacidad de manejo de la incertidumbre viene a costa de una carga computacional mayor, lo que puede ser limitante en hardware embebido con recursos reducidos como los de microcontroladores básicos o satélites [33]. Adicionalmente, en sistemas neuro-difusos, existe el riesgo de sobreajuste: el modelo puede aprender demasiado bien los datos de entrenamiento pero generalizarse pobremente a condiciones nuevas [23].

Finalmente, la carencia de pruebas formales de estabilidad sigue siendo un obstáculo para la adopción masiva en aplicaciones de seguridad crítica. Los sistemas híbridos (lógica difusa + redes neuronales + aprendizaje por refuerzo) son difíciles de analizar con criterios clásicos

como el de Lyapunov, lo que limita la confianza operativa en sectores conservadores como el aeroespacial [34].

22.4. Conclusiones

A lo largo de este capítulo se ha recorrido un campo que, sin hacer mucho ruido, lleva más de cinco décadas resolviendo problemas reales. La lógica difusa no prometió ser la solución universal a todos los problemas de control, y probablemente por eso ha sobrevivido y sigue siendo relevante cuando otros enfoques han venido y ido.

Lo que queda claro después de revisar la evidencia es que su principal fortaleza no es la precisión matemática, sino la capacidad de actuar bien cuando las condiciones no son perfectas: cuando los sensores mienten un poco, cuando el modelo del sistema no existe o es demasiado costoso de obtener, cuando el conocimiento disponible está en la cabeza de un técnico y no en una ecuación. En esas circunstancias, que describen una gran parte de los sistemas de control del mundo real, la lógica difusa ofrece algo que pocos métodos pueden igualar: resultados razonables con una complejidad de diseño manejable.

La variedad de dominios cubiertos por la literatura analizada es, en sí misma, un argumento. Que una misma técnica sea útil para controlar un robot colaborativo en una fábrica, ajustar los semáforos de una ciudad, gestionar la energía de una microrred, estabilizar un satélite y personalizar el entrenamiento de un atleta dice algo sobre su flexibilidad. No es que la lógica difusa sea siempre la mejor opción, sino que rara vez es una mala opción cuando el problema tiene incertidumbre y el diseñador tiene conocimiento del dominio.

Los sistemas híbridos, que combinan lógica difusa con redes neuronales y algoritmos evolutivos, representan la dirección más prometedora. La sinergia entre la interpretabilidad de la lógica difusa y la capacidad de aprendizaje de las redes neuronales produce sistemas que aprenden solos pero que aún pueden ser inspeccionados y comprendidos por un ingeniero, algo que los modelos de aprendizaje profundo puro difícilmente ofrecen.

Los desafíos que persisten son reales y no deben minimizarse. La dependencia del experto, la explosión de reglas y la dificultad de verificar formalmente la estabilidad de los sistemas híbridos son problemas abiertos. Pero también son problemas que la comunidad científica conoce bien y sobre los que trabaja de forma activa. La dirección parece ser la automatización del diseño: que el sistema sea capaz de construir sus propias reglas a partir de datos, ajustar sus propias funciones de membresía y demostrar su propia estabilidad, sin que un humano tenga que hacerlo todo a mano.

En última instancia, la lógica difusa es una prueba de que no siempre hace falta más precisión para obtener mejores resultados. A veces basta con ser lo suficientemente flexible para convivir con la imprecisión del mundo.

Referencias

- [1] S. Autso, O. Dunajeva, A. Pentel, O. Shvets, and M. Roosileht, “Application of Fuzzy Logic for Collaborative Robot Control,” *Electronics (Basel)*, vol. 14, no. 20, p. 4029, Oct. 2025, doi: 10.3390/electronics14204029.
- [2] C. Dumitrescu, P. Ciotirnae, and C. Vizitiu, “Fuzzy Logic for Intelligent Control System Using Soft Computing Applications,” *Sensors*, vol. 21, no. 8, p. 2617, Apr. 2021, doi: 10.3390/s21082617.
- [3] N. W. Madebo, “Enhancing Intelligent Control Strategies for UAVs: A Comparative Analysis of Fuzzy Logic, Fuzzy PID, and GA-Optimized Fuzzy PID Controllers,” *IEEE Access*, vol. 13, pp. 16548–16563, 2025, doi: 10.1109/ACCESS.2025.3532743.
- [4] S. Kamthan and H. Singh, “Hierarchical Fuzzy Logic for Multi-Input Multi-Output Systems,” *IEEE Access*, vol. 8, pp. 206966–206981, 2020, doi: 10.1109/ACCESS.2020.3037901.
- [5] K.-H. Choi and H.-J. Chang, “Improvement of Adaptive Cruise Control System Performance on Sloped Roads Based on Adaptive Neuro-Fuzzy Inference System,” *IEEE Access*, vol. 13, pp. 60519–60531, 2025, doi: 10.1109/ACCESS.2025.3557089.
- [6] N. Yousfi Allagui, F. A. Salem, and A. M. Aljuaid, “Artificial Fuzzy-PID Gain Scheduling Algorithm Design for Motion Control in Differential Drive Mobile Robotic Platforms,” *Computational Intelligence and Neuroscience*, vol. 2021, no. 1, Jan. 2021, doi: 10.1155/2021/5542888.
- [7] L. C. Sousa et al., “Obstacle Avoidance Technique for Mobile Robots at Autonomous Human-Robot Collaborative Warehouse Environments,” *Sensors (Basel)*, vol. 25, no. 8, p. 2387, Apr. 2025, doi: 10.3390/s25082387.
- [8] D. Mújica-Vargas, V. Vela-Rincón, A. Luna-Álvarez, A. Rendón-Castro, M. Matuz-Cruz, and J. Rubio, “Navigation of a Differential Wheeled Robot Based on a Type-2 Fuzzy Inference Tree,” *Machines*, vol. 10, no. 8, p. 660, Aug. 2022, doi: 10.3390/machines10080660.
- [9] F. A. A. Andrade et al., “Unmanned Aerial Vehicles Motion Control with Fuzzy Tuning of Cascaded-PID Gains,” *Machines*, vol. 10, no. 1, p. 12, Dec. 2021, doi: 10.3390/machines10010012.
- [10] A. G. Melo, F. A. A. Andrade, I. P. Guedes, G. F. Carvalho, A. R. L. Zachy, and M. F. Pinto, “Fuzzy Gain-Scheduling PID for UAV Position and Altitude Controllers,” *Sensors*, vol. 22, no. 6, p. 2173, Mar. 2022, doi: 10.3390/s22062173.
- [11] Y. Chu et al., “Interval Type-2 Fuzzy PID Controller Using Disassembled Gradational Optimization,” *Sensors*, vol. 23, no. 22, p. 9067, Nov. 2023, doi: 10.3390/s23229067.
- [12] A. Al-Mahturi, F. Santoso, M. A. Garratt, and S. G. Anavatti, “A Novel Evolving Type-2 Fuzzy System for Controlling a Mobile Robot under Large Uncertainties,” *Robotics*, vol. 12, no. 2, p. 40, Mar. 2023, doi: 10.3390/robotics12020040.

- [13] A. Ahmad et al., “An Optimal Acceleration Control for Collision Avoidance in VANETs Using Convex Optimization,” *Computers, Materials & Continua*, vol. 87, no. 3, pp. 1–10, 2026, doi: 10.32604/cmc.2026.076104.
- [14] Jitender, A. Dandona, R. Sharma, A. Garg, P. Dahiya, and A. Sharma, “Enhancing Autonomous Vehicle Safety with Fuzzy Logic-Based Collision Control in Traffic Lane,” in *2025 2nd International Conference on Computational Intelligence and Computing Applications (ICCICA)*, Samalkha, India, Oct. 30, 2025, pp. 137–142, doi: 10.1109/ICCICA67008.2025.11337618.
- [15] W. Dong, N. Zulkarnain, and M. F. Ibrahim, “Dual-Stage Adaptive Fuzzy MPC for Autonomous Vehicle Obstacle Avoidance,” *IEEE Access*, vol. 14, pp. 49068–49081, 2026, doi: 10.1109/ACCESS.2026.3678761.
- [16] S. Stavrinidis, P. Zacharia, and E. Xidias, “A Fuzzy Control Strategy for Multi-Goal Autonomous Robot Navigation,” *Sensors*, vol. 25, no. 2, p. 446, Jan. 2025, doi: 10.3390/s25020446.
- [17] A. Shaout and L. Castaneda-Trejo, “Fuzzy Logic Control for Adaptive Braking Systems in Proximity Sensor Applications,” *Electronics (Basel)*, vol. 14, no. 14, p. 2858, Jul. 2025, doi: 10.3390/electronics14142858.
- [18] G. Yang, S. Bekiros, Q. Yao, J. Mou, A. A. Aly, and O. R. Sayed, “Enhanced Control of Nonlinear Systems Under Control Input Constraints and Faults: A Neural Network-Based Integral Fuzzy Sliding Mode Approach,” *Entropy*, vol. 26, no. 12, p. 1078, Dec. 2024, doi: 10.3390/e26121078.
- [19] B. M. Al-Hadithi and J. Gómez, “Fuzzy Control of Multivariable Nonlinear Systems Using T–S Fuzzy Model and Principal Component Analysis Technique,” *Processes*, vol. 13, no. 1, p. 217, Jan. 2025, doi: 10.3390/pr13010217.
- [20] A. V. Martirosyan and D. V. Romashin, “Investigation of the Control Strategies for Enhancing the Efficiency of Natural Gas Separation and Purification Processes,” *Processes*, vol. 14, no. 4, p. 700, Feb. 2026, doi: 10.3390/pr14040700.
- [21] L. Skripko and A. Skripko, “Development of New Methods of Adaptive Control of Non-Stationary Systems During Transportation of Petroleum Products,” in *2025 9th International Conference on Information, Control, and Communication Technologies (ICCT)*, Gomel, Belarus, Oct. 7, 2025, pp. 1–5, doi: 10.1109/ICCT67028.2025.11427691.
- [22] M.-F. R. Lee, “A Review on Intelligent Control Theory and Applications in Process Optimization and Smart Manufacturing,” *Processes*, vol. 11, no. 11, p. 3171, Nov. 2023, doi: 10.3390/pr11113171.
- [23] M. Kharrat and P. Mercorelli, “A Comprehensive Review of Adaptive Control for Nonlinear Systems with Nonlinearities and Faults Using Fuzzy Logic and Neural Network Techniques,” *Mathematics*, vol. 14, no. 8, p. 1256, Apr. 2026, doi: 10.3390/math14081256.
- [24] Y. Li, “Design of a Cognitive Cloud-Network Framework for Intelligent System Integration in Distributed Data Centers,” in *2025 7th International Conference on Electronics and Communication, Network and Computer Technology (ECNCT)*, Guangzhou, China, Jul. 18, 2025, pp. 660–663, doi: 10.1109/ECNCT66493.2025.11172542.
- [25] S. Divya and D. K. Kumar, “Rule Based Energy Management Strategies of Fuel Cell Hybrid Electric Vehicle,” in *2025 2nd International Conference on Research Methodologies in Knowledge Management, Artificial Intelligence and Telecommunication Engineering (RMKMATE)*, Chennai, India, May 7, 2025, pp. 1–5, doi: 10.1109/RMKMATE64874.2025.11042570.

- [26] T. Khanduri, J. I. U. Ugli, Tanu, K. Gulhane, P. Gusain, and A. Sharma, “Fuzzy Logic-Based Optimization of Flood Control System,” in *2025 5th International Conference on Soft Computing for Security Applications (ICSCSA)*, Salem, India, Aug. 4, 2025, pp. 1698–1703, doi: 10.1109/ICSCSA66339.2025.11170953.
- [27] K. A. al Sumarmad, N. Sulaiman, N. I. A. Wahab, and H. Hizam, “Microgrid Energy Management System Based on Fuzzy Logic and Monitoring Platform for Data Analysis,” *Energies (Basel)*, vol. 15, no. 11, p. 4125, Jun. 2022, doi: 10.3390/en15114125.
- [28] A. Chojecki, A. Ambroziak, and P. Borkowski, “Fuzzy Controllers Instead of Classical PIDs in HVAC Equipment: Dusting Off a Well-Known Technology and Today’s Implementation for Better Energy Efficiency and User Comfort,” *Energies (Basel)*, vol. 16, no. 7, p. 2967, Mar. 2023, doi: 10.3390/en16072967.
- [29] S. Kaur, T. Kaur, and R. Khanna, “Adaptive Neuro-Fuzzy Inference System Based Output Power Controller in Grid-Connected Photovoltaic Systems,” *Energy Sources, Part A: Recovery, Utilization, and Environmental Effects*, vol. 47, no. 1, pp. 5183–5206, Jun. 2025, doi: 10.1080/15567036.2021.1890860.
- [30] P. Juniana and L. Hakim, “Traffic Light Control Using Fuzzy Logic Mamdani Method,” *Jurnal Terapan Teknologi Informasi*, vol. 3, no. 1, pp. 1–10, Jun. 2019, doi: 10.21460/jutei.2019.31.126.
- [31] R. Shenbagalakshmi, S. K. Mittal, J. Subramaniyan, V. Vengatesan, D. Manikandan, and K. Ramaswamy, “Adaptive Speed Control of BLDC Motors for Enhanced Electric Vehicle Performance Using Fuzzy Logic,” *Scientific Reports*, vol. 15, no. 1, p. 12579, Apr. 2025, doi: 10.1038/s41598-025-90957-6.
- [32] Y. Wu, A. S. A. Alwabel, Q. Xu, S. Alahmari, B. Alfasi, and A. Ahmadian, “SCO-Urban Flow: A Soft Computing Optimiser for Sustainable Traffic Management in Smart Cities,” *Applied Soft Computing*, vol. 198, p. 115279, Jul. 2026, doi: 10.1016/j.asoc.2026.115279.
- [33] J. C. Crespo, M. Royo, Á. Bello, K. Olfe, V. Lapuerta, and J. M. Ezquerro, “Design and Simulation Analysis of Attitude Control Algorithms for OPS-SAT-1,” *Aerospace*, vol. 13, no. 4, p. 320, Mar. 2026, doi: 10.3390/aerospace13040320.
- [34] M. Kamzan, J. Roshanian, M. Teshnehlab, M. Ghanifar, and A. A. Nikkhah, “Development of a Self-Organized Fuzzy Deep Reinforcement Learning-Based Controller with Application in an Earth-Oriented Satellite Attitude Control,” *Engineering Applications of Artificial Intelligence*, vol. 177, p. 114522, Aug. 2026, doi: 10.1016/j.engappai.2026.114522.
- [35] M. Yan, Y. Sun, M. Yan, and X. Cui, “Optimization of Sports Training Intensity Based on Fuzzy Control,” *International Journal of Computational Intelligence Systems*, vol. 19, no. 1, p. 75, Feb. 2026, doi: 10.1007/s44196-026-01158-6.